

RAG Fusion

本地 RAG 平台产品需求文档

V1.0 | 当前版本事实 + 阶段四规划

基线代码: 23ded66 | 2026-07-16

阶段一、二、三已收口 | 阶段四待实施

目录

1. 状态标记	3	11. 检索、答案与证据生成流程	20
2. 产品概述	3	12. 来源核验闭环	23
3. 用户与使用场景	5	13. 文档与任务状态	24
4. 产品原则与职责边界	5	14. 用量审计	25
5. 版本范围与阶段状态	6	15. 非功能需求	26
6. 功能架构	7	16. 当前版本验收标准	27
7. 功能需求	8	17. 阶段四规划	29
8. 逻辑架构	13	18. 风险与边界	31
9. 核心数据对象	15	19. 发布判定	31
10. 文档上传与入库流程	17	20. 术语表	32

文档属性	内容
产品名称	RAG Fusion 本地 RAG 平台
文档版本	V1.0
文档日期	2026-07-16
基线代码	23ded66 feat: complete stage 3 evidence source workflow
范围口径	当前版本事实 + 阶段四规划
当前阶段	阶段一、二、三已收口；阶段四待实施
适用范围	本地单机 MVP，面向文档入库、知识库检索与来源核验

本文是当前产品事实和下一阶段实施方向的统一 PRD。所有“已实现”能力均以当前代码、接口和阶段验收记录为依据；所有“规划”能力均归入阶段四，不代表已经交付。

1. 状态标记

标记	含义
已实现	当前版本已具备，并已有自动化或真实数据验收记录
部分实现	当前已有基础能力，但缺少产品化闭环、完整可观测性或通用验收
阶段四规划	当前版本未完成，计划在阶段四实施
上游能力	由 RAG-Anything、MinerU、LightRAG 或模型服务提供，产品层只接入和编排

2. 产品概述

2.1 产品定位

RAG Fusion 是一套独立产品化的本地 RAG 平台。平台不在产品层重新实现文档解析、语义切分、向量检索和知识图谱，而是复用以下成熟上游能力：

- RAG-Anything / MinerU：文档解析、多模态结构识别、content_list 和资产产出。
- LightRAG：正式入库、最终 chunk、向量与图谱索引、检索、rerank、答案和 reference。
- 产品层：知识库与文档生命周期、流程编排、参数规划、证据投影、来源核验、前端交互和用量审计。

当前 MVP 已跑通并收口：

上传 -> 画像与解析预览 -> 确认入库 -> LightRAG 正式索引

阶段四将重点补齐产品生命周期、图谱页面、完整用量审计、异常治理和通用 E2E 验收。

2.2 用户问题

本产品解决以下核心问题：

1. 本地文档解析、入库和检索工具分散，用户无法在一个产品中完成全流程操作。
2. 解析预览块、最终索引 chunk 和检索证据容易混淆，导致“看起来入库成功但实际索引不一致”。
3. 普通 RAG 答案缺少可核验来源，用户无法确认答案来自哪篇文档、哪一页、哪一段或哪个表格/图片。
4. 表格、图片和公式经常被降级为无意义标签或文本，无法参与检索和答案生成。
5. 模型调用、失败重试和重复调用缺少统一审计，成本与故障难以定位。

2.3 产品目标

当前版本目标

- 稳定完成单文档上传、解析预览、确认入库和状态同步。
- 以 LightRAG final chunk 为正式索引事实源。
- 使用 LightRAG 检索能力生成答案，不在产品层重建完整检索系统。
- 答案中的每个 [E] 证据都能打开用户可理解的来源资料。
- 来源资料可展示正文、结构化表格和图片，并支持页码与相关上下文核验。

阶段四目标

- 补齐知识库和文档的完整生命周期管理。
- 提供按知识库查看的图谱产品页。
- 建立覆盖解析、索引、查询、模型与重试的完整用量审计。
- 建立可重复执行的真实 E2E 验收与异常治理机制。

2.4 非目标

以下内容不属于当前 MVP 和阶段四范围：

- 自研替代 RAG-Anything、MinerU 或 LightRAG 的核心实现。
- 多租户、复杂权限、组织级数据隔离。
- 大规模批量上传和分布式任务调度。
- 复杂 BI 报表和财务结算系统。
- 为某一篇简历、论文或某一个问题编写硬编码规则。

3. 用户与使用场景

当前版本是本地单机产品，不实施角色权限控制。以下角色是产品使用视角，不代表已有 RBAC。

用户角色	核心诉求	典型任务
知识库管理员	管理知识库和文档状态	新建知识库、查看文档、确认最终 chunk、处理失败任务
文档运营人员	判断文档是否适合入库	上传文件、查看画像、检查解析文本与资产、确认入库
业务查询用户	获得有来源的可信答案	选择知识库、提问、查看答案、点击证据核验正文/表格/图片
运维与审计人员	定位故障和模型成本	查看调用次数、token、耗时、失败、重试和异常重复调用

3.1 核心场景

1. 上传 PDF 或 DOCX，先查看解析预览，再决定是否正式入库。
2. 在知识库管理页确认文档已完成 LightRAG 索引，并查看 final chunks。
3. 对一篇或多篇文档提出事实、对比、时间、表格或图片问题。
4. 从答案中的 [E] 打开来源，核验文档、页码、正文段落、表格或图片。
5. 发现回答异常时，通过查询记录、任务状态和用量事件定位问题阶段。

4. 产品原则与职责边界

4.1 核心原则

1. **事实源唯一**：解析预览不等于正式 chunk；正式 chunk 以 LightRAG final chunks 为准。
2. **上游优先**：解析、chunk、索引、检索和 rerank 优先使用上游原生能力。
3. **产品层适配而非重造**：产品层只做格式映射、参数规划、证据绑定和展示。
4. **证据优先**：答案不能伪造引用；没有可验证证据时必须明确降级。
5. **用户视角**：检索页不展示 chunk、block、bbox、内部 ID、调试状态等实现字段。
6. **通用性**：所有修复必须基于数据契约和类型规则，不针对单个样本硬编码。

4.2 职责边界

能力	RAG-Anything / MinerU	LightRAG	产品层
PDF/DOCX 文档解析	主责	可消费解析产物	编排、依赖检查、状态记录

能力	RAG-Anything / MinerU	LightRAG	产品层
文本/表格/图片/公式识别	主责	消费 sidecar/资产	无损映射、用户展示
解析候选块	产出结构基础	可生成 sidecar block	预览和人工确认
最终 chunk	不主责	主责	读取、展示、映射
向量/图谱索引	不主责	主责	workspace 编排和状态同步
查询与 rerank	不主责	主责	意图识别、参数透传、降级记录
答案生成	不主责	主责	证据约束、格式统一、用户展示
来源核验	提供页码、bbox、资产	提供 reference 、 final chunk、sidecar refs	组装用户证据闭环
用量审计	提供过程状态	提供调用与索引状态	统一记录、展示、告警

5. 版本范围与阶段状态

阶段	目标	当前状态	结论
阶段一	入库链路事实源切换	已实现	final chunk 主 权 已 切 回 LightRAG pipeline
阶段二	来源核验与资产展示	已实现	正文、表格、图片来源可面向用户展示
阶段三	LightRAG 检索能力补齐	已实现	查询参数、证据绑定、多文档和多模态检索已收口
阶段四	产品化收口与用量审计	部分实现 / 待实施	已有基础页面和记录，缺生命周期、图谱、完整审计与通用 E2E

6. 功能架构

6.1 功能架构图




图 1 功能架构图

6.2 页面结构

页面	路由	当前状态	主要功能
首页概览	<code>#/overview</code>	已实现	产品入口、知识库与任务概览
知识库管理	<code>#/knowledge-bases</code>	已实现	新建/删除知识库、文档列表、文档详情、final chunks、任务状态
文档入库	<code>#/document-ingestion</code>	已实现	上传、画像、解析预览、确认入库、任务状态
检索问答	<code>#/query</code>	已实现	检索参数、答案、证据卡片、来源核验
系统配置/用量监控	<code>#/settings</code>	部分实现	上游能力状态、用量汇总、调用事件
图谱中心	待新增	阶段四规划	按知识库查看实体、关系和图谱状态
Sidecar POC	<code>#/sidecar-poc</code>	内部隐藏	仅用于内部链路验证，不作为正式产品入口

7. 功能需求

7.1 首页概览

编号	需求	状态	验收要点
FR-OV-001	展示产品主要工作入口	已实现	可进入知识库、入库、检索和配置页面
FR-OV-002	展示知识库、文档和任务概览	已实现	数据来自产品 API，不使用静态示例
FR-OV-003	展示异常任务与待处理事项	阶段四规划	失败、超时、重试和待确认任务可直接进入处理

7.2 知识库管理

编号	需求	状态	验收要点
FR-KB-001	新建知识库并分配独立 LightRAG workspace	已实现	每个知识库有独立 workspace/端口映射
FR-KB-002	查看知识库及其正式入库文档	已实现	只把正式索引状态作为知识库事实
FR-KB-003	查看文档详情和 LightRAG final chunks	已实现	chunk 来源标识为 LightRAG final，不使用解析预览块冒充
FR-KB-004	删除知识库	已实现	删除前明确影响范围，状态与 workspace 一致
FR-KB-005	删除单篇文档并同步 LightRAG	阶段四规划	删除原文件、产品记录、索引和缓存，失败可恢复
FR-KB-006	查看知识库图谱状态	阶段四规划	展示实体/关系数量、构建状态和最后更新时间
FR-KB-007	大量知识库和文档快速加载	部分实现	阶段四补分页、懒加载、缓存和超时提示

7.3 文档上传、画像与解析预览

编号	需求	状态	验收要点
FR-IN-001	选择知识库并上传文档	已实现	保存原始文件、文件名、MIME、hash 和产品文档记录
FR-IN-002	上传前重复文件检测	已实现	同知识库相同内容可提示跳过

编号	需求	状态	验收要点
			或替换，不重复提交索引
FR-IN-003	生成文件画像和解析建议	已实现	给出解析器、索引模式和风险提示
FR-IN-004	调用 RAG-Anything/MinerU 生成解析结果	已实现	记录解析状态、耗时、错误和产物路径
FR-IN-005	DOCX 通过 LibreOffice 转换后解析	已实现	环境缺失时返回明确依赖错误，不伪装解析失败
FR-IN-006	展示按页解析文本与候选结构	已实现	明确“解析预览不是最终 chunk”
FR-IN-007	展示表格、图片和公式资产	已实现	不把 HTML、 <code><drawing></code> 或内部 JSON 直接展示给用户
FR-IN-008	点击确认后才进入正式索引	已实现	<code>parse-preview</code> 不得自动触发 <code>confirm-index</code>
FR-IN-009	支持重新解析	阶段四规划	保留版本和原因，避免覆盖可用产物后无法回退

7.4 正式入库与索引状态

编号	需求	状态	验收要点
FR-IDX-001	确认入库前检查解析预览已成功	已实现	非 <code>preview_ready</code> 文档不能正式提交
FR-IDX-002	复用已完成解析产物并提交 LightRAG pipeline	已实现	产品层不把自有 traceable chunks 作为正式索引输入
FR-IDX-003	由 LightRAG 生成 final chunks、vector、graph 和 doc_status	已实现	final chunk 事实来自 workspace 存储
FR-IDX-004	索引进行中持续同步 track/doc_status	已实现	前端不在请求刚返回时误报“入库成功”
FR-IDX-005	重复提交保护	已实现	已索引文档默认跳过，记录 <code>duplicate_guard</code>
FR-IDX-006	替换已有文档	部分实现	当前支持删除上游副本后重提；阶段四补完整版本策略和失败回滚
FR-IDX-007	失败任务恢复	部分实现	已有 recover API；阶段四补前端入口、重试上限和审计闭

编号	需求	状态	验收要点
			环

7.5 检索问答

编号	需求	状态	验收要点
FR-Q-001	选择知识库并提交问题	已实现	查询范围不跨未选择知识库
FR-Q-002	支持 <code>vector/graph/hybrid/mix/multimodal</code> 模式	已实现	默认使用 <code>mix</code> ，参数真实透传
FR-Q-003	支持 <code>top_k</code> 、 <code>chunk_top_k</code> 、 <code>token</code> 预算等参数	已实现	参数进入 LightRAG 请求和审计记录
FR-Q-004	查询意图识别和参数规划	已实现	只规划参数和文档范围，不替代上游生成答案
FR-Q-005	使用 <code>/query/data</code> 获取可核验候选	已实现	用于证据候选、诊断和降级，不直接向用户展示内部数据
FR-Q-006	使用 LightRAG <code>answer</code> 生成正式答案	已实现	答案基于选定知识库及检索上下文
FR-Q-007	请求上游 rerank	已实现 / 上游可观测性受限	无法确认单次执行时记录 <code>unknown_unobservable</code> ，不得伪造成功
FR-Q-008	支持正文、表格、图片和混合证据	已实现	资产可以参与候选选择、答案和来源展示
FR-Q-009	支持多文档对比	已实现	各文档证据不被第一篇高分候选挤占，分段引用不交叉
FR-Q-010	证据不足时拒绝伪绑定	已实现	返回“未返回可核验证据”或受控弱答，不附无关来源

7.6 答案与证据绑定

编号	需求	状态	验收要点
FR-EV-001	答案事实句使用 <code>[E1]</code> 等证据编号	已实现	编号必须对应最终证据对象
FR-EV-002	对正文、表格、图片采用统一 <code>evidence</code> 契约	已实现	前端不依赖上游原始返回结构
FR-EV-003	精确表格问题按行、列和值进	已实现	不能把 <code>adjusted difference</code>

编号	需求	状态	验收要点
	行字段级绑定		当成组内 Mean (SD)
FR-EV-004	图片问题优先绑定目标图片及其 caption/OCR/VLM summary	已实现	无视觉语义时不虚构图片内容
FR-EV-005	去除重复和未绑定证据	已实现	同一资产或同一事实不重复显示多张来源卡
FR-EV-006	跨文档总结至少保留每篇文档的直接证据	已实现	总结性结论可由多条证据共同支持

7.7 来源核验

编号	需求	状态	验收要点
FR-SRC-001	来源卡显示文档、页码和资料类型	已实现	不显示 chunk、block、bbox、分数和排序调试字段
FR-SRC-002	点击来源打开证据弹窗	已实现	弹窗标题明确证据编号、文档和页码
FR-SRC-003	展示答案中使用该证据的内容	已实现	只显示与当前证据绑定的答案句或数据项
FR-SRC-004	正文证据展示原文段落和相关上下文	已实现	可定位到对应页面与解析文本位置
FR-SRC-005	表格证据展示结构化表格	已实现	宽表格横向滚动，长表格纵向滚动
FR-SRC-006	图片证据展示真实图片	已实现	图片可点击放大、缩小和关闭，不以 alt 文本代替图片
FR-SRC-007	mixed 证据组合展示	已实现	只展示与答案相关的正文和资产，不带出整页所有图片

7.8 系统配置与用量监控

编号	需求	状态	验收要点
FR-OPS-001	查看 RAG-Anything/MinerU/LightRAG 能力状态	部分实现	当前有 capabilities；阶段四补依赖健康和版本信息
FR-OPS-002	查看模型用量摘要	部分实现	已有 summary API；阶段四补维度筛选和趋势

编号	需求	状态	验收要点
FR-OPS-003	查看模型调用事件	部分实现	已有 events API；阶段四补分页、失败聚合和导出
FR-OPS-004	记录解析、索引、查询和模型调用	部分实现	当前覆盖主链路；阶段四补全跨进程和上游细粒度事件
FR-OPS-005	异常重复调用阻断	阶段四规划	按 operation、文档、任务和时间窗识别并阻断
FR-OPS-006	失败重试审计	阶段四规划	每次重试必须关联原任务、原因、次数和最终结果
FR-OPS-007	成本预算与告警	阶段四规划	支持单任务/单知识库预算和异常耗时告警

8. 逻辑架构

8.1 逻辑架构图




图 2 逻辑架构图

8.2 部署形态

- 当前为 Windows 本地单机部署。
- 前端默认运行于 `127.0.0.1:5173`，产品 API 默认运行于 `127.0.0.1:8081`。
- 每个知识库绑定独立 LightRAG workspace 服务和端口，避免索引互相污染。
- 产品元数据保存在 SQLite；原文件、解析产物和资产保存在本地文件系统。
- RAG-Anything/MinerU、LightRAG、模型和 LibreOffice 作为外部依赖，由产品配置和能力接口检查。

8.3 API 能力分组

分组	主要接口	说明
健康与能力	GET <code>/health</code> 、 GET <code>/v1/capabilities</code>	服务和依赖能力检查

分组	主要接口	说明
知识库	GET/POST /v1/knowledge-bases 、 GET/DELETE /v1/knowledge-bases/{id}	知识库生命周期
文档入库	uploads 、 profile 、 parse-preview、 confirm-index	上传到正式索引的分步流程
文档与资产	documents/{id}、 chunks、 source-blocks、 assets	文档详情、final chunks 和来源资产
任务与状态	tasks 、 pipeline-status 、 tasks/recover	状态收敛和失败恢复
检索	POST /v1/knowledge-bases/{id}/query	查询规划、LightRAG 检索、答案和证据
来源核验	GET /v1/knowledge-bases/{id}/citations/{citation_id}/source	返回面向用户的正文/表格/图片证据
用量	GET /v1/model-usage/summary 、 events	调用摘要和事件明细

9. 核心数据对象

9.1 数据对象关系图




图 3 核心数据对象关系图

9.2 事实源定义

数据	正式事实源	产品层用途
原始文件	产品本地文件区	下载、预览、重新解析
解析结构	RAG-Anything/MinerU 产物	解析预览、sidecar 适配、来源定位
解析候选块	产 品 <code>traceable_chunks</code> / sidecar preview	人工检查，不作为正式索引 chunk
最终 chunk	LightRAG workspace final chunks	知识库详情、检索证据入口

数据	正式事实源	产品层用途
向量与图谱	LightRAG workspace	检索和阶段四图谱展示
答案与 reference	LightRAG query + 产品证据绑定结果	最终答案和用户证据编号
来源位置与资产	final chunk refs + sidecar + source blocks/assets	文档页、正文、表格、图片核验
任务与用量	产品 SQLite + 上游状态/日志	状态收敛、审计和告警

10. 文档上传与入库流程

10.1 文件上传与前置检查流程




图 4 文件上传与前置检查流程图

10.2 解析预览与人工确认流程




图 5 解析预览与人工确认流程图

11. 检索、答案与证据生成流程

11.1 查询规划与检索候选流程




图 7 查询规划与检索候选流程图

11.2 答案生成与证据绑定流程




图 8 答案生成与证据绑定流程图

11.3 用户证据发布与来源入口流程




图 9 用户证据发布与来源入口流程图

11.4 查询模式规则

模式	当前用途	产品规则
vector	纯语义相似度检索	适合明确事实和近义表达，作为受控降级模式之一
graph	实体与关系线索	适合关系型问题；无图谱数据时不得伪装命中
hybrid	向量与图谱组合	保留兼容能力，记录实际模式
mix	当前默认综合模式	平衡 chunk、实体和关系线索
multimodal	表格、图片等资产问题	结合 caption、OCR、VLM summary 和资产 refs

11.5 回答准确性约束

产品层不能保证模型永远正确，但必须通过以下契约降低错误并使错误可核验：

1. 只允许已选择知识库的检索候选进入答案上下文。
2. 答案中的事实必须绑定到正文、表格或图片证据；不能用未绑定候选装饰答案。
3. 精确数值优先使用结构化表格字段，不从拼接文本猜列关系。
4. 多文档问题必须按文档保留候选配额，并限制分段引用不跨文档。
5. 图片没有 caption、OCR 或 VLM summary 时只能展示来源，不能推测图片内容。
6. 上游回答与证据冲突时，以可核验原始资料为准，并触发弱答或不回答策略。
7. 所有降级、fallback、重试和证据删除必须写入审计信息，普通用户界面不显示调试字段。

12. 来源核验闭环

12.1 来源链路图




图 10 来源核验闭环图

12.2 用户展示契约

检索结果页只展示：

- 答案正文和 [E] 证据编号。
- 来源文档名、页码和资料类型。
- 与答案直接相关的正文、表格或图片。

检索结果页不展示：

- chunk ID、block ID、reference 内部 ID。
- bbox、raw JSON、sidecar 路径。
- 相关度、排序依据和内部 fallback 细节。
- source mapping missing、unknown_unobservable 等调试状态。

上述内部信息仅保留在后端日志、诊断接口和用量审计中。

13. 文档与任务状态

13.1 状态机




图 11 文档与任务状态机

13.2 状态展示规则

内部状态	用户文案	是否可操作
uploaded / profiling	文件已上传，正在生成画像	可返回列表，不可确认入库
preview_parsing	正在解析文档	可查看进度，不可确认入库
preview_ready	解析预览已完成，等待确认入库	可查看预览、确认入库
indexing	已提交 LightRAG，正在建立索引	可查看真实状态，不显示已成功
indexed	已入库	可检索、查看 final chunks
failed	处理失败	展示用户可理解原因和恢复入口
rebuild_required	需要重建知识库索引	展示影响范围，必须二次确认
skipped	已存在相同索引，已跳过	不重复调用上游

14. 用量审计

14.1 当前记录范围

环节	operation 示例	当前状态
上传/重复检测	duplicate_guard、confirm_index	已记录
RAG-Anything/MinerU 解析	parse status、elapsed、error	部分记录
LightRAG 索引	track/doc_status、final chunk count	已记录主状态
Query Planner	query_rewrite / skipped	已记录
查询候选	query_data	已记录 mode、候选和 fallback
正式答案	answer	已记录耗时和可获得 token
Rerank	rerank	记录 requested；单次不可观测时为 unknown_unobservable
图片分析	VLM / multimodal processing	可从上游产物和日志确认，产品统一事件仍需补齐
Embedding 、 entity/relation 、 summary	LightRAG indexing 内部调用	上游有日志，产品细粒度统一审计仍需阶段四补齐

14.2 阶段四统一事件模型

每条调用事件至少包含：

字段	说明
provider	product、RAG-Anything、MinerU、LightRAG 或模型供应方
model	实际模型名；无法确认时明确为 unknown，不猜测
operation	parse、embedding、entity、relation、summary、vlm、rerank、answer 等
knowledge_base_id	所属知识库
document_id / query_id / task_id	可追踪业务对象
prompt_tokens / completion_tokens / total_tokens	可获得的 token 数据
cache_hit	是否命中缓存
elapsed_seconds	实际耗时
status	succeeded、failed、skipped、unknown_unobservable
retry_of / retry_count	重试链路

字段	说明
error	失败原因和上游返回摘要
raw_json	仅供内部诊断的原始元数据

14.3 异常治理要求

- 1. 同一文档、相同 operation 在短时间重复触发时，先检查任务是否仍在运行。
- 2. 已成功且输入未变化的解析、索引或查询派生任务应使用缓存或跳过。
- 3. 自动重试必须有最大次数、退避间隔和幂等键。
- 4. 发生异常 token、超长耗时或连续失败时生成告警事件。
- 5. 上游不可观测能力必须标记“不确定”，不能推断为成功。

15. 非功能需求

15.1 可靠性

- 服务重启后知识库、文档、任务、查询、证据和用量记录不丢失。
- 正式状态必须由可验证上游状态和产物共同确认。
- 上传、确认入库和查询具备基本幂等保护。
- 来源资产文件不存在时，页面降级为可用文本证据并记录内部告警。

15.2 性能

- 页面列表必须采用分页、懒加载或增量加载，不能一次读取所有重型详情。
- 知识库列表加载不应等待每个 workspace 的完整深度扫描。
- 解析、索引和查询均为长任务，前端必须展示明确进度或等待状态。
- 表格和图片在来源弹窗中按需加载，不阻塞答案主体展示。

阶段四建议目标值：

指标	目标
首页与知识库列表首屏	本地正常环境 P95 小于 2 秒
文档列表首屏	P95 小于 3 秒，重型详情延迟加载
来源弹窗文本证据	P95 小于 2 秒
来源弹窗资产证据	P95 小于 5 秒，显示加载状态
状态轮询	不高于每 2 秒一次，任务完成后停止

15.3 可用性

- 正式页面使用中文用户文案。
- 长表格支持横向和纵向滚动；滚动区域不能遮挡关闭按钮。
- 图片预览支持点击放大、缩小、复位和关闭。
- 所有失败状态提供原因和下一步操作，不只显示“失败”。
- 不能让用户理解 chunk、block 或内部引用结构后才能使用产品。

15.4 安全与隐私

- 默认仅监听本地回环地址，不主动暴露公网。
- 原文件、解析产物、索引和日志保存在本地配置目录。
- API key 不写入前端和普通日志。
- 阶段四在删除知识库或文档前必须展示数据影响范围并二次确认。

15.5 可维护性

- 上游适配逻辑必须集中在 adapter/client 边界，不散落在页面和业务规则中。
- 每次升级 RAG-Anything/MinerU/LightRAG 时执行契约测试和真实样本回归。
- 证据契约必须覆盖正文、表格、图片、mixed 和多文档场景。
- 文档、API 模型和前端类型保持同步。

16. 当前版本验收标准

16.1 主流程验收

1. 新建知识库后形成独立 LightRAG workspace 映射。
2. 上传 PDF，成功生成画像和解析预览；预览不会自动入库。
3. 上传 DOCX，在 LibreOffice 可用时完成转换和解析；缺失依赖时给出明确错误。
4. 点击确认入库后先显示处理中，只有 LightRAG final chunks 可读取时显示已入库。
5. 知识库管理页的 chunk 数和内容来自 LightRAG final chunks。
6. 重启 API 和 LightRAG workspace 后，知识库、文档和状态仍可读取。

16.2 检索与证据验收矩阵

类型	示例问题	必须满足
正文事实	某文档的核心能力是什么？	答案事实来自正文，来源打开对应段落

类型	示例问题	必须满足
时间顺序	第一份/最近一份工作是什么？	命中正确时间段，不靠单文档硬编码
精确表格	Table 3 某行两组数值分别是多少？	数值、列归属正确，来源直接打开结构化表格
图片说明	这张流程图说明什么？	绑定目标图片，不重复展示其他图表
指定 Figure/Table	Figure 2 / 表 3 中.....	同编号跨文档时按文档范围和语义区分
多文档对比	比较两篇研究的方案和结论	两篇文档均有证据，分段引用不交叉
证据不足	文档未包含的问题	不编造答案，不附无关来源

16.3 来源核验验收

- 每个显示给用户的 [E] 都可点击。
- 弹窗显示“答案中的依据、来源资料、相关原文上下文”。
- 正文证据显示文档和相关段落。
- 表格证据显示真实结构化表格，横向与纵向滚动可用。
- 图片证据显示真实图片，放大、缩小、复位和关闭可用。
- 页面不得出现 chunk ID、block ID、bbox、raw JSON 和映射错误文案。

16.4 当前验证基线

截至 2026-07-16，当前提交基线的已记录验证结果：

- 后端阶段相关测试：288 passed, 2 subtests passed。
- 前端测试：14 passed。
- 前端生产构建：通过。
- 精确表格来源可映射到真实 asset-table-4，来源类型为 table，展示模式为 asset。
- 证据绑定契约版本：chunk-bindings-v18。

以上结果是当前代码基线，不替代阶段四的通用真实 E2E 验收。

17. 阶段四规划

17.1 阶段四目标分解图




图 12 阶段四目标分解图

17.2 实施优先级

优先级	子阶段	目标	依赖
P0	4-A 生命周期收口	删除、替换、重解析、恢复、列表性能	当前知识库和任务基础
P0	4-C 完整用量审计	统一主链路调用事实	当前 model_usage 和上游日志
P0	4-D 异常治理	重复阻断、重试、告警	4-A、4-C
P1	4-B 图谱产品页	把 LightRAG 图谱能力产品化	当前 LightRAG graph 数据
P0	4-E 通用 E2E 与发布	完整回归和 MVP 发布门禁	4-A 至 4-D

17.3 阶段四详细验收

生命周期

- 单篇文档删除后，产品记录、原文件、来源资产和 LightRAG 索引状态一致。
- 替换文档失败时，旧版本可继续检索或可明确恢复。
- 重新解析和重新入库不会产生重复 final chunks 或重复模型调用。
- 知识库和文档列表在真实数据量下满足性能目标。

图谱

- 用户可按知识库查看实体和关系。
- 图谱数据直接来自 LightRAG，不在产品层重建第二份图谱。
- 支持加载中、空结果、失败和更新时间状态。
- 图谱节点可追溯到相关文档或来源信息。

用量与异常

- 可按时间、知识库、文档、查询、operation、provider、model 和状态筛选。
- 入库链路可看到 parse、index、embedding、entity、relation、summary、VLM 等实际事件或明确不可观测边界。
- 查询链路可看到 planner/rewrite、query_data、answer、rerank 和 fallback。
- 重复调用被阻断时有明确事件；失败重试可还原完整链路。
- token 和耗时异常可定位到具体任务和 operation。

E2E 发布门禁

至少覆盖：

创建知识库

- > 上传 PDF
- > 上传 DOCX
- > 画像与解析预览
- > 确认入库与状态收敛
- > 查看 final chunks
- > 正文事实查询
- > 精确表格查询
- > 图片/流程图查询
- > 多文档对比
- > 来源核验
- > 用量审计
- > 服务重启
- > 失败恢复
- > 文档删除

任一 P0 用例失败，不允许标记 MVP 最终版本通过。

18. 风险与边界

风险	当前表现	处理策略
上游版本变化	sidecar、query 或 storage 结构可能变化	固定版本、契约测试、升级前真实样本回归
MinerU 解析质量波动	双栏、旁注、扫描件可能错序或漏字	保留解析预览；区分上游解析问题与 adapter 问题
LightRAG P/Pi 合并策略	final chunks 数量与预览块不同	以 final chunk 为事实源，使用诊断报告，不通过 size 硬调
Rerank 单次不可观测	无法证明某次请求实际执行	保持 <code>unknown_unobservable</code> ，阶段四补日志关联或等待上游能力
表格结构复杂	跨行跨列表头可能影响字段绑定	使用结构化 table 契约和字段级验证，不拼接猜测
图片缺少语义	无 caption/OCR/VLM summary 时无法回答图意	只展示来源，不生成视觉幻觉；必要时重新解析入库
本地依赖缺失	LibreOffice、模型、上游服务不可用	capabilities 检查、明确错误、阶段四健康诊断
数据量增长	知识库页面加载变慢	阶段四分页、懒加载、索引摘要和缓存

19. 发布判定

19.1 当前版本判定

- 阶段一、二、三功能基线已完成。
- 当前版本可进入阶段四开发，不等于 MVP 最终产品已发布。
- 当前用户核心链路可用：上传、解析预览、确认入库、检索问答、来源核验。

19.2 MVP 最终版本判定

只有同时满足以下条件，才可标记阶段四和 MVP 最终版本完成：

1. 阶段四 P0 生命周期、用量、异常治理和 E2E 全部通过。
2. 真实 PDF、DOCX、表格、图片和多文档样本完成全链路验收。
3. 删除、替换、重试和服务重启不造成状态或索引不一致。
4. 每个用户可见证据都能打开对应正文、表格或图片。
5. 页面不暴露内部调试字段，异常能在审计页面定位。
6. 已知上游边界被如实记录，不用产品层伪造成功状态或数据。

20. 术语表

术语	定义
解析预览	RAG-Anything/MinerU 解析后供用户检查的按页文本、候选块和资产，不是最终 chunk
sidecar	LightRAG 可消费的文档结构与来源引用数据，包括 blocks、positions 和资产 refs
final chunk	LightRAG pipeline 生成并用于正式索引和检索的 chunk
source block	可定位到页码和 bbox 的解析文本块，是来源上下文的基础对象
asset	表格、图片/绘图或公式等结构化来源资料
reference	LightRAG 返回的答案或检索引用对象
citation	产品层保存的答案证据绑定记录
user evidence	面向用户展示的统一证据对象，只包含可理解的来源资料
evidence binding	将答案中的具体句子或数据项绑定到直接支持它的来源证据
workspace	每个知识库独立的 LightRAG 运行和存储空间